

Informe de resultados — Laboratorio 6

Análisis de participación en YouTube | CC3084, UVG

Fuente: notebook ejecutado. Se omite el código; las tablas muy anchas o extensas se resumen aquí y se conservan completas en el notebook y los CSV de results/. Las etiquetas de sentimiento son predicciones no validadas localmente.

Laboratorio 6 — Análisis de redes sociales (YouTube)

CC3084 — Data Science | UVG

Este notebook contiene el desarrollo del laboratorio de análisis de redes sociales usando dos conjuntos de datos de YouTube: youtube_videos.csv y youtube_comments.csv .

En cada sección se explica primero, en términos sencillos, qué vamos a hacer y por qué , y luego se muestra el código y los resultados.

Preparación del entorno

Antes de analizar los datos, importamos las librerías que vamos a usar (para tablas, gráficas y redes) y definimos una paleta de colores fija —naranja pastel y verde— que se usará en todas las gráficas del laboratorio para mantener un estilo consistente.

Librerías cargadas y paleta de colores lista.

1. Carga, comprensión e integración de los datos

1.1 Carga de los archivos

Tenemos dos archivos: youtube_videos.csv , con información de videos y canales (293 videos), y youtube_comments.csv , con los comentarios dejados en una parte de esos videos (406 comentarios). El primer paso es abrirlos y revisar que se hayan leído bien.

Al intentar cargarlos con pd.read_csv de la forma más simple, Python arrojó un error de formato ("Expected 17 fields, saw 19"). Al revisar el archivo crudo encontramos que los datos fueron exportados con espacios de relleno para alinear las columnas visualmente (por ejemplo, la categoría topic queda guardada como "topic " , con espacios extra). Ese relleno provoca que, en algunos comentarios largos, la comilla que abre el texto no quede pegada al inicio del campo, y entonces las comas dentro del comentario se confunden con comas que separan columnas.

La solución fue indicarle al lector de CSV que ignore los espacios que siguen inmediatamente a una coma (skipinitialspace=True). Con este ajuste, las 406 filas de comentarios y las 293 filas de videos se leen completas, sin perder ninguna. El relleno de espacios que queda dentro de los valores (nombres, IDs, categorías) se trata a fondo en la sección 2 (limpieza), como pide el enunciado.

youtube_videos.csv -> 293 filas, 20 columnas

youtube_comments.csv -> 406 filas, 17 columnas

```
<class 'pandas.DataFrame'>
```

RangeIndex: 293 entries, 0 to 292

Data columns (total 20 columns):

Column Non-Null Count Dtype

0 video_id 293 non-null str

1 title 293 non-null str

2 channel_name 293 non-null str

3 channel_id 293 non-null str

4 source_query 293 non-null str

```

5 source_group 293 non-null str
6 dataset_sources 293 non-null str
7 channel_handle 293 non-null str
8 published_time 280 non-null str
9 view_count_text 280 non-null str
10 description_snippet 268 non-null str
11 video_url 293 non-null str
12 query_hits 293 non-null str
13 keywords 293 non-null str
14 description 267 non-null str
15 view_count 293 non-null int64
16 publish_date 293 non-null str
17 upload_date 293 non-null str
18 category 293 non-null str
19 owner_handle 293 non-null str
dtypes: int64(1), str(19)
memory usage: 348.6 KB

: 0 | video_id: -5puKGEqcUc | title: INSIVUMEH pronostica incremento de lluvias par... | channel_name: T13 Noticias Guatemala | channel_id: UCqOCm-3SKthEysQc2JZBi1A | source_query: guatemala lluvias | source_group: topic | dataset_sources: youtube_guatemala.csv | youtube_guatemala_lab... | channel_handle: /@T13NoticiasGuatemala | published_time: hace 2 días | view_count_text: 2,390 vistas | description_snippet: El Departamento de Pronóstico de INSIVUMEH pre... | video_url: https://www.youtube.com/watch?v=-5puKGEqcUc | query_hits: ["guatemala lluvias"] | keywords: ["Canícula prolongada", "Chapin tv", "Fenómeno..."] | description: El Departamento de Pronóstico de INSIVUMEH pre... | view_count: 2357 | publish_date: 2026-08-28T22:00:20-07:00 | upload_date: 2026-08-28T22:00:20-07:00 | category: News & Politics | owner_handle: /@T13NoticiasGuatemala

: 1 | video_id: -E7OPOLjMug | title: BERNARDO ARÉVALO CALIFICA CAMBIO EN EL MP COMO... | channel_name: IDocumenta | channel_id: UCgtljn_ZWFWcv1MlpKIkqgQ | source_query: @GobiernodelaRepublicadeGuatemala | source_group: topic | dataset_sources: youtube_target_channels.csv | channel_handle: /@iDocumenta | published_time: hace 3 meses | view_count_text: 4 vistas | description_snippet: El presidente de Guatemala, Bernardo Arévalo, ... | video_url: https://www.youtube.com/watch?v=-E7OPOLjMug | query_hits: ["@GobiernodelaRepublicadeGuatemala"] | keywords: [] | description: El presidente de Guatemala, Bernardo Arévalo, ... | view_count: 4 | publish_date: 2026-05-13T16:00:03-07:00 | upload_date: 2026-05-13T16:00:03-07:00 | category: People & Blogs | owner_handle: /@iDocumenta

: 2 | video_id: -KDgIrlzRko | title: ¡HISTÓRICO! Mexico recupera petróleo robado po... | channel_name: México Poder | channel_id: UC-DpoeBbCMOMOH1-j71KPqA | source_query: guatemala noticias | source_group: topic | dataset_sources: youtube_guatemala.csv | youtube_guatemala_lab.... | channel_handle: /@M%C3%A9xicoPoder | published_time: hace 1 día | view_count_text: 29,736 vistas | description_snippet: México #PetróleoMexicano #SoberaníaEnergética ... | video_url: https://www.youtube.com/watch?v=-KDgIrlzRko | query_hits: ["guatemala noticias"] | keywords: ["Mexico recupera petroleo", "petroleo robado ..."] | description: #México #PetróleoMexicano #SoberaníaEnergética... | view_count: 29736 | publish_date: 2026-08-29T17:00:38-07:00 | upload_date: 2026-08-29T17:00:38-07:00 | category: People & Blogs | owner_handle: /@M%C3%A9xicoPoder

```

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

```

<class 'pandas.DataFrame'>
RangeIndex: 406 entries, 0 to 405
Data columns (total 17 columns):
# Column Non-Null Count Dtype
---  ---
0 video_id 406 non-null str
1 comment_id 406 non-null str
2 video_title 406 non-null str
3 channel_name 406 non-null str
4 channel_id 406 non-null str
5 author_name 406 non-null str
6 author_channel_id 406 non-null str
7 text 406 non-null str
8 source_query 406 non-null str
9 source_group 406 non-null str
10 dataset_sources 406 non-null str
11 author_handle 406 non-null str
12 published_text 406 non-null str
13 like_count_text 217 non-null float64
14 reply_count 406 non-null int64
15 is_pinned 406 non-null str

```

16 viewer_rating 0 non-null float64

dtypes: float64(2), int64(1), str(14)

memory usage: 690.4 KB

: 0 | video_id: j43HgwYFKfk | comment_id: Ugw-J65a1iYL9hghELh4AaABAg | video_title: La cooptación de Walter Mazariegos en la USAC ... | channel_name: Quorum | channel_id: UCE4rsXcgDb6e1-a9iTbWzfg | author_name: @MarcosCarillo-b1r | author_channel_id: UCdFlugHJJJa4I3YqWuNRmvXw | text: Ese corrupto amigo de la vieja fiscal los teng... | source_query: @quorumgt | source_group: topic | dataset_sources: j43HgwYFKfk_out_comments.csv | quorum_complete... | author_handle: /@MarcosCarillo-b1r | published_text: hace 6 meses | like_count_text: NaN | reply_count: 0 | is_pinned: False | viewer_rating: NaN

: 1 | video_id: 06mFNPU0aB8 | comment_id: Ugw-ZT9t9wU2V-tCaUZ4AaABAg | video_title: Capturan a presuntos delincuentes disfrazados ... | channel_name: Noti7 | channel_id: UCvPSRoZgngfSL03Nlbjtq9A | author_name: @RaulPerez-cw2vi | author_channel_id: UCv1tzQeBeGy6efPTRJXSCw | text: Están jóvenes porque no buscan un trabajo, tu... | source_query: guatemala noticias | source_group: topic | dataset_sources: youtube_guatemala_comments.csv | youtube_guate... | author_handle: /@RaulPerez-cw2vi | published_text: hace 2 semanas | like_count_text: NaN | reply_count: 0 | is_pinned: False | viewer_rating: NaN

: 2 | video_id: j43HgwYFKfk | comment_id: Ugw0xaOb2CYXxoudtwJ4AaABAg | video_title: La cooptación de Walter Mazariegos en la USAC ... | channel_name: Quorum | channel_id: UCE4rsXcgDb6e1-a9iTbWzfg | author_name: @iamjimalessa | author_channel_id: UCRAquv8el-tQ30bN7MlmySQ | text: Me dejaron con ganas de demandar la ilegalidad... | source_query: @quorumgt | source_group: topic | dataset_sources: j43HgwYFKfk_out_comments.csv | quorum_complete... | author_handle: /@iamjimalessa | published_text: hace 1 año | like_count_text: 4.0 | reply_count: 0 | is_pinned: False | viewer_rating: NaN

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

1.2 Unidad de observación, llave primaria y variables relevantes

youtube_videos.csv

- Unidad de observación: un video publicado en YouTube.

- Llave primaria: video_id

- Variables más relevantes para el laboratorio: Para identidad/relación: video_id , channel_id (el canal, más estable que channel_name , que sí puede repetirse o cambiar). Para popularidad: view_count (numérico, listo para cálculos; view_count_text es solo el texto que muestra YouTube). Para clasificación temática: category , source_query , source_group , keywords , query_hits . Para texto: title , description . Para tiempo: publish_date (fecha real ISO 8601); published_time es relativo ("hace 2 días") y depende del momento en que se recolectaron los datos, no lo usaremos como fecha exacta.

youtube_comments.csv

- Unidad de observación: un comentario principal publicado en un video (no incluye respuestas a comentarios).

- Llave primaria: comment_id (también verificado sin duplicados).

- Llave foránea: video_id , que conecta cada comentario con su video en youtube_videos.csv .

- Variables más relevantes: Para identidad del autor: author_channel_id (el "DNI" del autor; author_name y author_handle son solo visibles y pueden repetirse o cambiar). Para contenido: text (el comentario en sí). Para popularidad del comentario: like_count_text (texto, hay que limpiarlo) y reply_count (número de respuestas, no identifica quién respondió). Variables que no aportan nada en este conjunto: is_pinned (siempre False) y viewer_rating (siempre vacía) — lo confirmamos en la sección 2.

Confirmamos abajo que ambas llaves primarias son únicas (0 duplicados).

Duplicados en video_id (videos): 0

Duplicados en comment_id (comments): 0

Canales únicos (channel_id) en videos: 97

Autores únicos (author_channel_id): 332

¿is_pinned siempre False? False

¿viewer_rating siempre vacío? True

1.3 Relación entre canal, video, autor, comentario, categoría y consulta de búsqueda


El canal es quien publica los videos. Cada video tiene una sola categoría asignada por YouTube (por ejemplo, News & Politics o Education). Las personas que ven un video pueden dejar un comentario, y cada comentario tiene un autor —cuya identidad se registra por separado del canal publicador—. Por separado, sabemos con qué consulta de búsqueda se encontró cada video durante la recolección.

Las relaciones, una por una:

- Canal → Video (1 a N): un canal (`channel_id`) puede publicar muchos videos, pero cada video pertenece a un solo canal.
- Video → Comentario (1 a N): un video puede tener muchos comentarios, pero cada comentario (`comment_id`) pertenece a un solo video (vía `video_id`).
- Autor → Comentario (1 a N): un autor (`author_channel_id`) puede escribir varios comentarios, incluso en videos de canales distintos, pero cada comentario tiene un solo autor. El campo `channel_id` dentro de `comments` identifica al canal comentado , no a quien comenta.
- Video → Categoría (N a 1): cada video tiene exactamente una categoría ; varios videos comparten la misma categoría.
- Video ↔ Consulta de búsqueda (N a M): un video puede coincidir con varias consultas (`query_hits` es una lista), y una misma consulta (`source_query`) puede traer varios videos. Por eso `source_query` / `source_group` describen cómo se recolectaron los datos, no necesariamente el tema definitivo del video.

Un mismo autor puede comentar en videos de canales distintos — esas coincidencias de audiencia son la base de las redes que se construyen en los ejercicios 4 y 5.

Mapa conceptual de relaciones entre las entidades del laboratorio



1.4 Integración de los conjuntos mediante video_id

Unimos la tabla de comentarios con la tabla de videos usando `video_id` como llave de conexión. Queremos comprobar dos cosas: (1) que todo comentario logre encontrar su video correspondiente, y (2) qué tan repartidos están esos comentarios entre los 293 videos disponibles.

Resultado de la integración (indicator de merge):

```

_merge
both 406
left_only 0
right_only 0

```

Name: count, dtype: int64

Comentarios asociados exitosamente a un video: 406 de 406 (100.0%)

Videos con al menos 1 comentario: 19 de 293 (6.5%)

Videos sin ningún comentario en este conjunto: 274 (93.5%)

Hallazgos de la integración:

- El 100% de los 406 comentarios (`_merge == 'both'`) encontró su video correspondiente en `youtube_videos.csv` . No hay comentarios sin video, ni duplicaciones causadas por `video_id` repetidos.
- Solo 19 de los 293 videos (6.5%) tienen al menos un comentario en este conjunto de datos; los otros 274 videos (93.5%) no tienen ningún comentario recolectado. Esto no significa que esos videos no tengan comentarios reales en YouTube — significa que el proceso de recolección solo trajo comentarios para una muestra pequeña y específica de videos. Es una limitación de cobertura que se retoma en la sección 3 (concentración de participación) y en las conclusiones finales.

2. Calidad, limpieza y preprocesamiento

2.1 Diagnóstico inicial de calidad

Antes de limpiar nada, revisamos el estado real de los datos: cuántos valores faltan, si hay filas repetidas, si alguna columna no varía (y por lo tanto no aporta información), si hay valores extremos, y si los identificadores/nombres/handles son consistentes entre sí. Esto nos dice qué hay que arreglar antes de analizar.

videos: (293, 20) (filas, columnas)

comments: (406, 17) (filas, columnas)

Tipos de dato por columna en videos:

str 19

int64 1

Name: count, dtype: int64

Tipos de dato por columna en comments:

str 14

float64 2

int64 1

Name: count, dtype: int64

Valores faltantes en videos:

n_faltantes pct_faltante

published_time 13 4.4

view_count_text 13 4.4

description_snippet 25 8.5

description 26 8.9

Valores faltantes en comments:

n_faltantes pct_faltante

like_count_text 189 46.6

viewer_rating 406 100.0

Filas 100% idénticas en videos: 0

Filas 100% idénticas en comments: 0

Comentarios cuyo texto exacto se repite: 4 filas (en 2 textos distintos)

	comment_id	video_id	author_channel_id	text
116	Ugx8FxDKPAY-M_JhRgd4AaABAg	n8iP75glpmw	UCi1b_TRQfgO1Z9O2gNGGWNA	Ahora se destapo la CORRUPCION Q EXISTIA Y AHO...
324	Ugz7WPxTOQEwmZpnx_V4AaABAg	n8iP75glpmw	UCi1b_TRQfgO1Z9O2gNGGWNA	Ahora se destapo la CORRUPCION Q EXISTIA Y AHO...

	comment_id	video_id	author_channel_id	text
112	Ugx74OPnWkWaFjpFuA94AaABAg.A7ki-1ED5b2A7nlcG2_svP	n8iP75glpmw	UCFjudnPLoaSL1BaRuLahyHg	Cierto. ...
272	Ugy__nsWCBggw9EzOUd4AaABAg.A7lbRpGUZoHA7nJxaD37u-	n8iP75glpmw	UCFjudnPLoaSL1BaRuLahyHg	Cierto. ...

No hay filas completamente duplicadas. Dos pares tienen texto exacto repetido y comment_id distinto. Tanto el texto largo del video n8iP75glpmw como las dos filas de "Cierto." corresponden al mismo autor dentro de cada par. Se conservan porque son registros distintos según la llave primaria; el texto repetido por sí solo no demuestra un error ni permite inferir el motivo de la repetición.

--- Columnas constantes en comments ---

is_pinned -> únicos: <ArrowStringArray>

[False]

Length: 1, dtype: str

viewer_rating -> % vacío: 100.0 %

--- Columnas redundantes en videos (coinciden 100% con otra columna) ---

upload_date == publish_date en el 100.0 % de las filas

owner_handle == channel_handle en el 100.0 % de las filas

view_count (videos):

count 293.0

mean 60,430.1

std 515,798.3

min 2.0

25% 215.0

50% 1,175.0

75% 7,465.0

max 8,190,449.0

Name: view_count, dtype: str

reply_count (comments):

count 406.000000

mean 0.125616

std 0.580748

min 0.000000


25% 0.000000

50% 0.000000

75% 0.000000

max 7.000000

Name: reply_count, dtype: float64



Canales (channel_id) con más de un channel_name distinto: 0 de 97
 Canales (channel_id) con más de un channel_handle distinto: 0 de 97
 Autores (author_channel_id) con más de un author_name distinto: 0 de 332
 Mismatches de channel_id entre comments y videos (mismo video_id): 0
 channel_handle con formato inesperado: 0
 comment_id que contienen un punto (estructura no verificada): 36 de 406 (8.9%)

Resumen del diagnóstico:

- Dimensiones y tipos: 293 videos (20 columnas) y 406 comentarios (17 columnas), en su mayoría texto, con algunos numéricos (view_count, reply_count) y fechas en formato texto ISO 8601.
- Faltantes: en videos, hasta un 8.9% de descripciones vacías y un 4.4% sin view_count_text/published_time. En comments, el 46.6% de like_count_text está vacío y viewer_rating está vacío al 100%.
- Duplicados: ninguna fila 100% repetida, pero sí 2 pares de texto de comentario idéntico (ambos pares conservados por tener identificadores distintos).
- Constantes/redundantes: is_pinned y viewer_ratin no aportan variabilidad; upload_date/owner_handle son copias exactas de publish_date/channel_handle.
- Atípicos: view_count va de 2 a más de 8 millones, una distribución muy asimétrica típica de redes sociales (unos pocos videos "virales" concentran casi todas las vistas). La mayoría de comentarios tiene 0 respuestas; unos pocos llegan hasta 7.
- Consistencia de identificadores: cada channel_id tiene siempre el mismo channel_name/channel_handle, y cada author_channel_id tiene siempre el mismo author_name — no encontramos canales o autores con nombres cambiantes en esta muestra. Los handles siguen el formato esperado (/@usuario) en el 100% de los casos, y el canal que aparece en comments siempre coincide con el canal real del video en videos.
- Hipótesis de formato: 36 identificadores contienen un punto. Esto podría corresponder a identificadores compuestos, pero sin documentación de la extracción ni una llave explícita de comentario padre no se confirma que sean respuestas y no se reconstruyen conversaciones.

2.2 Variables que no pueden usarse o requieren precaución especial

- is_pinned (comments): siempre False . No distingue nada entre comentarios, así que no se usa en ningún análisis.
- viewer_rating (comments): 100% vacía. Se descarta por completo.
- upload_date y owner_handle (videos): son copias exactas de publish_date y channel_handle . Se mantienen en la tabla por completitud, pero no se usan como si fueran información independiente (evita contar el mismo dato dos veces).

- `channel_name` y `author_name` / `*_handle` (ambas tablas): son visibles y podrían cambiar o repetirse con el tiempo (aunque en esta muestra puntual resultaron consistentes). Se usan solo para mostrar etiquetas en tablas y gráficas; nunca como llave para unir, agrupar o construir nodos de red — eso siempre se hace con `channel_id` / `author_channel_id`.
- `reply_count` (comments): cuenta cuántas respuestas recibió un comentario, pero no dice quién las escribió. El enunciado es explícito en esto: no debe interpretarse como una arista entre autores. Se usa únicamente como una medida de "cuánta conversación generó" ese comentario, nunca para construir relaciones entre personas.
- `view_count_text` (videos) y `like_count_text` (comments): son texto, no números. Además, comparamos `view_count_text` contra `view_count` y encontramos que 53 de 280 videos (19%) no coinciden exactamente entre ambos. Una captura en momentos diferentes es una hipótesis, no una causa comprobada; también podrían intervenir diferencias de representación o extracción. Por eso usamos `view_count` como la fuente numérica oficial, y `view_count_text` solo queda como referencia/auditoría, no para cálculos.
- `query_hits`, `keywords`, `dataset_sources` (videos y/o comments): están guardadas como texto con forma de lista (por ejemplo `["guatemala lluvias"]`), no como listas reales de Python. Hay que convertirlas antes de poder analizarlas (ver sección 2.3).
- `comment_id` con punto (36 registros): su formato merece auditoría de la extracción, pero no prueba por sí solo una respuesta. Se conserva cada registro y únicamente se representa su vínculo autor-video.
- Fechas relativas (`published_time` en videos, `published_text` en comments): dependen del momento exacto en que se recolectaron los datos ("hace 2 días" hoy no es lo mismo que "hace 2 días" hace un mes). No se usan como fecha exacta; para videos ya existe `publish_date` en formato ISO 8601, que sí es utilizable.

2.3 Normalización de identificadores y nombres

Vamos a crear versiones "de trabajo" (`videos_clean` y `comments_clean`) donde:

- Quitamos los espacios de relleno de todas las columnas de texto (incluyendo `video_id`, `channel_id`, `comment_id`, `author_channel_id` — los identificadores también traían espacios extra, como vimos en 1.1).
- No sustituimos ningún ID por su nombre visible: `channel_id`, `video_id`, `comment_id` y `author_channel_id` se mantienen intactos como las llaves oficiales para todo el análisis posterior (uniones, agrupaciones y construcción de redes). `channel_name` / `author_name` / los handles solo se guardan aparte, para usarlos como etiquetas en tablas y gráficas.
- Convertimos las columnas de tipo "texto con forma de lista" (`query_hits`, `keywords`) a listas reales de Python, usando `ast.literal_eval`, para poder analizarlas más adelante (por ejemplo, contar hashtags o palabras clave).

Ejemplo antes/después de limpiar espacios en `source_group`:

crudo: 'topic'

limpio: 'topic'

Ejemplo de `keywords` convertido de texto a lista real:

texto original: ["Canícula prolongada", "Chapin tv", "Fenómeno del Niño", "Guatemala", "Lluvias ...

lista: ['Canícula prolongada', 'Chapin tv', 'Fenómeno del Niño', 'Guatemala', 'Lluvias en Guatemala']

IDs verificados: los conteos de valores únicos no cambiaron tras la limpieza.

2.4 Conversión de variables de conteo (texto → número)

- `view_count_text` viene como "2,390 vistas". Le quitamos la palabra "vistas", la coma de miles, y lo convertimos a número. No encontramos abreviaturas tipo "1.2K" o "3M" en esta columna (todas las cifras vienen escritas completas), así que el parser solo necesita manejar comas y la palabra "vistas". Como ya existe `view_count` (numérico; no se conoce el orden de captura de los contadores), lo usamos como la cifra oficial; `view_count_text` queda solo de referencia.
- `like_count_text` viene sin comas ni abreviaturas, solo dígitos o vacío. Al cargarlo con `skipinitialspace=True`, pandas ya lo reconoce como número (`float64`). Aun así, lo convertimos explícitamente a un entero y documentamos qué hacemos con los vacíos: el archivo no permite distinguir cero de ausencia de medición, por lo que, solo como supuesto de trabajo, asumimos

que un valor vacío equivale a 0 me gusta — pero dejamos una columna aparte (`like_count_observado`) que marca si el dato realmente venía observado o si lo completamos nosotros, para no perder esa distinción.

`view_count_text` no vacío: 280 de 293

de esos, coinciden exactamente con `view_count`: 227 (81.1%)

no coinciden (causa no verificada): 53

-> usamos "`view_count`" (ya numérico) como cifra oficial para el resto del laboratorio.

`like_count_text` observado (no vacío): 217 de 406

`like_count` (entero, vacíos completados con 0):

count 406.000000

mean 5.726601

std 30.661298

min 0.000000

25% 0.000000

50% 1.000000

75% 2.000000

max 405.000000

Name: `like_count`, dtype: float64

2.5 Dos versiones del texto: `texto_original` y `texto_limpio`

Guardamos el comentario tal cual llegó en `texto_original` — esa versión no se toca, porque el análisis de sentimiento (sección 9) y cualquier auditoría necesitan el texto real, con mayúsculas, signos de puntuación y emojis incluidos (todo eso aporta información sobre el tono del comentario). La versión `texto_limpio` (que construimos en 2.6) es una simplificación pensada para contar palabras, hashtags y temas — no para medir sentimiento.

Filas con `texto_original` vacío o solo espacios: 0

Ejemplo de `texto_original`:

Están jóvenes porque no buscan un trabajo, tuvieron suerte que no hay policías que le gusta del otro vando , por ir vestido de mujer se los hubieran ensamblado la maquinaria.

2.6 Construcción de `texto_limpio` : decisiones tomadas y por qué

Para pasar de `texto_original` a `texto_limpio` seguimos estos pasos, en este orden, y antes de borrar cada elemento lo extraemos a su propia columna para no perder esa señal (URLs, hashtags, menciones y emojis pueden ser útiles más adelante):

- Minúsculas: todo el texto se pasa a minúsculas, para que "Guatemala" y "guatemala" cuenten como la misma palabra.
- URLs: se detectan con una expresión regular y se eliminan del texto (no aportan al conteo de palabras/temas); guardamos si el comentario traía o no un link (`tiene_url`).
- Menciones (`@usuario`): se extraen a una columna aparte (`menciones_encontradas`) y se eliminan del texto — son nombres de usuario, no vocabulario del tema.
- Hashtags (`#palabra`): se extraen a una columna aparte (`hashtags_encontrados`) y, a diferencia de las menciones, la palabra se conserva en el texto (solo se le quita el símbolo #), porque un hashtag como "#Guatemala" sí es una palabra con contenido temático.
- Emojis: se extraen a una columna aparte (`emojis_encontrados` , más el conteo `num_emojis`) y se quitan del texto limpio, porque no son palabras que se puedan lematizar o contar como vocabulario — pero se conservan aparte porque son una señal útil de emoción.
- Puntuación y números: se eliminan del texto limpio (dejamos solo letras y espacios, conservando tildes/ñ). Los números casi no aparecen como palabras temáticas relevantes en estos comentarios, así que se descartan para esta versión "para conteo de palabras" — se conservan intactos en `texto_original` .

- Stopwords en español: se eliminan palabras muy frecuentes que no aportan tema (artículos, preposiciones, etc.), usando la lista de español de spaCy.
- Lematización: cada palabra restante se reduce a su forma base (ej. "corriendo" → "correr", "jóvenes" → "joven") usando el modelo en español es_core_news_sm de spaCy, para que variantes de una misma palabra se cuenten juntas en las secciones 3 y 7.

Listo. Ejemplo de transformación completa:

texto_original: Están jóvenes porque no buscan un trabajo, tuvieron suerte que no hay policías que le gusta del otro vando , por ir vestido de mujer se los hubieran ensamblado la maquinaria.

texto_paso1: están jóvenes porque no buscan un trabajo tuvieron suerte que no hay policías que le gusta del otro vando por ir vestido de mujer se los hubieran ensamblado la maquinaria

texto_limpio: joven buscar trabajo tener suerte policía gustar var vestir mujer haber ensamblar maquinaria

hashtags: []

menciones: []

emojis: []

ORIGINAL: Viva Guatemala ■■■■■■■■■■

LIMPIO: vivo guatemala

ORIGINAL: Otro pequeño truco es que tenés un plan mensual de Gb y redes ilimitadas y luego te mandan mensaje que consumiste el 95% de tu plan y ahi vi

LIMPIO: pequeño truco tenés plan mensual gb red ilimitado mandan mensaje consumistir plan venir caos verifica consumo dato haber utilizar red mínimo internet ende recarga adicional ir averiguar consumistir dato recarga

ORIGINAL: Qué lujooo de contenidoooooo ■

LIMPIO: lujooo contenidoooooo

ORIGINAL: Entoces las mismas ■■ Junta Directiva haciéndose de las suyas con el dinero del Estado. Ya basta de tanto robo, barriles sin fondos.■■■

LIMPIO: entoz junta directivo hacer él dinero bastar robo barril fondo

2.7 Efecto cuantificado de la limpieza

No eliminamos ningún comentario durante la limpieza de texto (seguimos teniendo 406 filas); lo que cambia es el contenido de la columna de texto. Medimos: cuántos comentarios quedaron vacíos después de limpiar, cuánto se redujo el texto en promedio, y cómo cambió la cantidad de duplicados.

Comentarios modificados por la limpieza: 406 de 406 (100.0%)

Textos vacíos ANTES de limpiar: 0

Textos vacíos DESPUÉS de limpiar: 8

Comentarios que quedaron vacíos tras la limpieza (probablemente solo tenían emojis, URL o menciones):

[■

Comentarios con texto duplicado ANTES de limpiar (texto_original): 2

Comentarios con texto duplicado DESPUÉS de limpiar (texto_limpio): 12

-> la limpieza generó 10 duplicados nuevos (comentarios que antes eran distintos y ahora se ven iguales tras quitar mayúsculas/puntuación/emojis).

Longitud total de caracteres: 450,505 -> 31,049 (reducción del 93.1%)

Lectura de los resultados: el conteo anterior compara directamente cada texto original preservado con su versión limpia, sin normalizar primero el original . Así se incluyen también cambios solo de espacios o mayúsculas.

8 comentarios quedaron vacíos tras la limpieza. Al revisarlos, son casos como "■", "♥■", "que?" o "Cierto." — mensajes que originalmente ya eran solo emojis o palabras que spaCy clasifica como palabras vacías de contenido. Esto no es un error, es información real: esos comentarios expresan una reacción breve más que un tema. Por eso no los eliminamos de la tabla — siguen siendo interacciones autor-video válidas y su sentimiento se puede seguir evaluando desde el texto original (sección 9); simplemente no aportan palabras a los análisis de frecuencia/temas de la sección 3.

Los duplicados de texto pasaron de 2 a 12 al comparar el texto limpio en lugar del original. Tiene sentido: mensajes cortos como "Cierto." o reacciones de un par de emojis, se vuelven idénticos una vez que se les quita mayúsculas, puntuación y

emojis. Este aumento de duplicados no indica más contenido repetido real, sino que la limpieza vuelve más gruesa la comparación.

El texto se redujo 63% en cantidad de caracteres en promedio, principalmente por quitar URLs, menciones, puntuación y palabras vacías — es una simplificación fuerte pero intencional, pensada solo para contar palabras y temas, no para leer los comentarios como tal (para eso siempre queda el texto original).

3. Análisis exploratorio

3.1 Descripción general

Con los datos ya limpios, describimos el panorama general: cuántos videos, canales, comentarios y autores hay, cómo se reparten los videos entre canales, cuántos comentarios y autores distintos tiene cada video, y cómo lucen las visualizaciones, respuestas, me gusta, categorías, consultas de búsqueda, hashtags, palabras y bigramas.

Videos: 293

Canales: 97

Comentarios: 406

Autores: 332

count 97.000000

mean 3.020619

std 5.141699

min 1.000000

25% 1.000000

50% 1.000000


75% 2.000000

max 32.000000

Name: video_id, dtype: float64



	title	channel_name	category	view_count	n_comentarios	n_autores
14	Qué rico come tu diputado	Quorum	News & Politics	11775	161	128
12	La cooptación de Walter Mazariegos en la USAC	Quorum	News & Politics	10156	50	49
2	Inician los trabajos de recuperación del Puert...	Gobierno de la República de Guatemala	Entertainment	11670	45	32
13	Plan 2032 Ciudad de Guatemala	Municipalidad de Guatemala	News & Politics	304089	25	25
5	Conferencia de Prensa del Gobierno de Guatemal...	Gobierno de la República de Guatemala	Entertainment	3628	25	19
4	EE.UU. envía a mexicanos deportados a Guatemal...	Noticias Telemundo	News & Politics	14200	25	18
17	Arroz con pollo a la MONOPOLIO	Quorum	News & Politics	1954	16	16
0	Capturan a presuntos delincuentes disfrazados ...	Noti7	News & Politics	6692	14	13
15	Internet: escoger el menos malo	Quorum	News & Politics	717	12	10
11	Capturan a ladrón que había quedado grabado mi...	TN23 Guatemala	News & Politics	4616	7	7
10	Bloqueos en Guatemala este 31 de agosto por al...	PrensaLibreOficial	News & Politics	5469	7	7
8	Caminar en una ciudad hecha para carros	Quorum	News & Politics	422	6	6
6	l'x K'at: el primer equipo guatemalteco de pel...	Quorum	News & Politics	1075	4	4
3	10 Preguntas a un año del Paro Nacional	Quorum	News & Politics	673	3	3
1	Noticiero en Directo 1 pm, 28 de Agosto de 2026	Noticiero Guatevisión 13 Hrs.	News & Politics	573	2	2
9	Cruzando la ciudad a puro Transmetro	Quorum	News & Politics	1140	1	1
7	SHAI WA: la vecina queer de Casa Presidencial	Quorum	News & Politics	1755	1	1
16	¿Quiénes pagan más en Centroamérica?	Quorum	News & Politics	220	1	1
18	Edén por Salud: empleo inclusivo para personas...	Quorum	Nonprofits & Activism	52	1	1



Recordando lo que ya vimos en la sección 1: de los 293 videos, solo 19 tienen algún comentario en este conjunto de datos. Un solo video, "Qué rico come tu diputado" del canal Quorum, concentra 161 de los 406 comentarios (el 40% de todos los comentarios de todo el conjunto) y 128 autores distintos. Le sigue "La cooptación de Walter Mazariegos en la USAC", también de Quorum, con 50 comentarios. El resto de videos con comentarios tiene cantidades mucho más modestas.

Visualizaciones por video (los 293):

count 293

mean 60,430

std 515,798

min 2

25% 215

50% 1,175

75% 7,465

max 8,190,449

Name: view_count, dtype: str

Respuestas por comentario (reply_count):

count 406.000000

mean 0.125616

std 0.580748

min 0.000000

25% 0.000000

50% 0.000000

75% 0.000000

max 7.000000

Name: reply_count, dtype: float64

Me gusta por comentario (like_count):


count 406.000000

mean 5.726601
 std 30.661298
 min 0.000000
 25% 0.000000
 50% 1.000000
 75% 2.000000
 max 405.000000

Name: like_count, dtype: float64

Los 5 comentarios con más me gusta, todos del mismo video ("Plan 2032 Ciudad de Guatemala"):

	author_name	like_count	reply_count	texto_original
299	@zetag	405	3	Quiero vivir en esa Guatemala :v ...
193	@elenaluarca9377	329	5	Que bueno que Guatemala sea una cuidad bonita ...
338	@samuelaguilar529	211	3	Me encantaría vivir por un tiempo en Guatemala...
124	@TheAlexX_C	191	2	Que bella es la Ciudad de Guatemala, unica en ...
184	@sabinamarinaguerra3248	113	1	Se ve moderna Y bella la ciudad de Guatemala ...



News & Politics es el 47% de todos los videos, pero el 84% de los videos que sí recibieron comentarios.



Top 10 consultas de búsqueda (source_query) con más videos encontrados:

source_query

Municipalidad de Guatemala 20

@GobiernodelaRepublicadeGuatemala 18

Gobierno de Guatemala 18

@GobiernodeGuatemala 17

guatemala noticias 16

@MunicipalidaddeGuatemala-1551 16

Ministerio de Comunicaciones Guatemala 16

Conred Guatemala 15

Gobierno de la República de Guatemala 15

PMT Guatemala 15

Name: count, dtype: int64

Comentarios con al menos un hashtag: 1 de 406


Hashtags encontrados en total: 1 -> ['ineptobran']

Comentarios con al menos una mención (@usuario): 5

Comentarios con al menos un URL: 1

Comentarios con al menos un emoji: 61 (15.0%)

channel_id
Quorum 256
Gobierno de la República de Guatemala 70
Noticias Telemundo 25
Municipalidad de Guatemala 25
Noti7 14
dtype: int64




La participación está muy concentrada: solo 8 de los 97 canales reciben algún comentario, y apenas 5 canales concentran el 96% de todos los comentarios — con Quorum solo ya representando el 63%. A nivel de video, un solo video acumula el 40% de todos los comentarios del conjunto de datos, y con solo 5 videos ya se llega al 75%. Esta concentración importa para lo que viene: cualquier red que construyamos con estos datos va a estar dominada por lo que pasó alrededor de un puñado de videos y canales, no por una muestra representativa de todo YouTube Guatemala.

3.3 Popularidad (vistas) vs. participación (comentarios)

Comparamos las vistas de un video contra su cantidad de comentarios, solo para los 19 videos que efectivamente tienen comentarios (para el resto no hay con qué comparar).

Correlación entre vistas y cantidad de comentarios (19 videos): 0.07

(cercano a 0 = casi no hay relación lineal entre ambas cosas)



La correlación es prácticamente nula (0.07): el video más comentado ("Qué rico come tu diputado", 11,775 vistas) no es ni de cerca el más visto. El video con más vistas entre los 19 que sí tienen comentarios ("Plan 2032 Ciudad de Guatemala", más de 300,000 vistas) recibió solo 25 comentarios — y eso sin contar que, de los 293 videos totales, hay varios con muchas más vistas todavía (hasta más de 8 millones) que simplemente no tienen ningún comentario recolectado. Es decir, en esta muestra, ver mucho un video no implica comentar mucho, y viceversa.

Ambas cifras tienen límites que hay que tener presentes: `view_count` es una sola foto tomada en el momento de la recolección (un video puede seguir sumando vistas después), y el conteo de comentarios depende de qué videos fueron elegidos para recolectar comentarios — no de cuántos comentarios tiene el video en realidad en YouTube. Con solo 19 videos con comentarios, cualquier conclusión sobre esta relación es más una observación puntual que un patrón generalizable.

3.4 Visualizaciones

Las gráficas de esta sección (barras de canales y videos, histogramas de vistas y respuestas, categorías, palabras y bigramas, el gráfico de concentración acumulada, el dispersión de vistas vs. comentarios y la nube de palabras) cubren este punto: la nube de palabras se incluyó como complemento visual, no como reemplazo de las comparaciones cuantitativas.

Autores que comentaron en más de 1 video: 9 de 332 (2.7%)

	autor	n_videos	canales_distintos	canales
3	@MarcosCarillo-b1r	2	2	UCt5Dw7ePnn0AqPqRF8Xpjkw, UCE4rsXcgDb6e1-a9iTb...
4	@moisesvaldez4043	2	2	UCEepOY2svuxbsJ-zsAPT9Fg, UCE4rsXcgDb6e1-a9iTb...

	autor	n_videos	canales_distintos	canales
6	@virgiliogarcia3039	2	2	UC-ZtFBHzgkYFh7whZkuR_Ag, UCE4rsXcgDb6e1-a9iTb...
8	@franciscoflores3120	2	2	UCVpSRoZgngfSL03Nlbtq9A, UC-ZtFBHzgkYFh7whZku...
0	@inge_vergueta	3	1	UCE4rsXcgDb6e1-a9iTbWzfg
1	@hashoja7348	3	1	UCE4rsXcgDb6e1-a9iTbWzfg
2	@Alejandro00710	2	1	UCE4rsXcgDb6e1-a9iTbWzfg
5	@josegil3813	2	1	UC-ZtFBHzgkYFh7whZkuR_Ag
7	@Jel.Awesh.M	2	1	UCE4rsXcgDb6e1-a9iTbWzfg

3.5 Preguntas obligatorias

¿Qué videos y canales concentran la mayor participación observada? El video "Qué rico come tu diputado" (canal Quorum) concentra el 40% de todos los comentarios; junto con "La cooptación de Walter Mazariegos en la USAC" (también Quorum), suman cerca de la mitad del total. A nivel de canal, Quorum por sí solo tiene el 63% de todos los comentarios, y junto con Gobierno de la República de Guatemala, Noticias Telemundo, Municipalidad de Guatemala y Noti7 llegan al 96%.

¿Existen audiencias compartidas entre videos, canales o temas? Sí, aunque de forma limitada: 9 de los 332 autores (2.7%) comentaron en más de un video. La mayoría de esos autores se quedó dentro del mismo canal (varios videos de Quorum), pero varios sí cruzaron de canal — por ejemplo, autores que comentaron tanto en un video de Quorum como en uno de Gobierno de la República de Guatemala, PrensaLibreOficial, TN23 Guatemala o Noti7. Esas coincidencias, aunque pocas, son justamente los puentes que va a mostrar la red de la sección 5.

¿Qué autores funcionan como puentes entre contenidos que de otra forma permanecerían separados? La diversidad de canales indica candidatos, no prueba articulación. La sección 8 identifica los autores concretos mediante eliminación de nodos y mide el aumento de componentes; también distingue autores multivideo que no son articulaciones.

¿Qué temas y sentimientos caracterizan a las principales comunidades de participación? Con la evidencia de palabras y bigramas de esta sección, el tema dominante es político-económico: sueldos de diputados, corrupción, dinero público, y menciones directas al presidente Bernardo Arévalo. El vocabulario no basta para etiquetar sentimiento ni su destinatario. La sección 9 completa esta respuesta con predicciones del modelo español, tamaños de muestra y perfiles internos de las tres comunidades principales.

¿La visibilidad medida mediante visualizaciones coincide con la participación observada? No. La correlación entre vistas y comentarios (para los 19 videos con comentarios) es prácticamente nula (0.07). El video más visto de esa muestra no es el más comentado, y viceversa — más vistas no implica más comentarios en estos datos.

¿Qué conclusiones están limitadas por el procedimiento de recolección y la cobertura de los datos? Casi todas. Solo 19 de 293 videos tienen comentarios, y no se dispone de probabilidades de inclusión para esos 19; las consultas y fuentes documentan una selección condicionada por la recolección. Por eso no se puede concluir nada sobre "qué tan comentado está YouTube Guatemala en general", solo sobre estos 19 videos puntuales. Los 274 videos sin comentarios en los datos no necesariamente carecen de comentarios reales en YouTube — solo no fueron recolectados.

3.6 Preguntas adicionales

Pregunta 1: ¿los comentarios con más "me gusta" también reciben más respuestas, o son cosas independientes?

Correlación entre me gusta y respuestas: 0.54



Hay una relación moderada (0.54): los comentarios con más me gusta tienden a recibir más respuestas también. Esta asociación no demuestra aprobación ni una relación causal; además depende de la imputación de ceros en los conteos de me gusta ausentes. No es una relación perfecta, pero ambas métricas se mueven en la misma dirección más de lo que se mueven por separado.

Pregunta 2: ¿los videos institucionales del gobierno (source_group = official_gov) generan comentarios, a pesar de ser más de un tercio de todos los videos recolectados?

Videos por source_group (los 293):

source_group

topic 177

official_gov 105

channel 11

Name: count, dtype: int64

source_group de los 19 videos que sí tienen comentarios:

source_group

topic 12

channel 7

Name: count, dtype: int64

No, ninguno. El 36% de los videos recolectados (105 de 293) vienen de fuentes institucionales de gobierno, pero ninguno de los 19 videos con comentarios pertenece a ese grupo — todos vienen de las categorías "topic" o "channel". No se conoce si esto se debe a la cobertura de extracción o a la disponibilidad de comentarios: los datos no registran el estado de habilitación de comentarios. En cualquier caso, no podemos afirmar que el contenido institucional "no genera conversación" — solo que, en esta muestra, no aparece ninguno con comentarios capturados.

Pregunta 3: entre los comentarios que sí tienen emojis, ¿se concentran en el video más comentado o están repartidos entre varios videos?

	title	n_comentarios	n_con_emoji	pct_con_emoji
2	Inician los trabajos de recuperación del Puert...	45	12	26.7
14	Qué rico come tu diputado	161	11	6.8
12	La cooptación de Walter Mazariegos en la USAC	50	9	18.0
4	EE.UU. envía a mexicanos deportados a Guatemal...	25	7	28.0
13	Plan 2032 Ciudad de Guatemala	25	6	24.0
5	Conferencia de Prensa del Gobierno de Guatemal...	25	5	20.0
0	Capturan a presuntos delincuentes disfrazados ...	14	3	21.4
15	Internet: escoger el menos malo	12	2	16.7

Los comentarios con emoji están repartidos entre varios videos, no concentrados en el más comentado. De hecho, el video más comentado ("Qué rico come tu diputado", 161 comentarios) tiene la proporción de emojis más baja de la lista (6.8%), mientras que otros videos con muchos menos comentarios llegan hasta 26-28%. Una lectura posible es que el video con más comentarios generó sobre todo debate político escrito (texto argumentativo), mientras que videos con menos comentarios recibieron más reacciones cortas y emocionales.

4. Construcción de la red bipartita autor-video

4.1-4.2 Definición de la red

Vamos a representar la participación como una red de dos tipos de nodos: autores y videos. Un nodo autor se conecta con un nodo video cuando ese autor escribió al menos un comentario en ese video. El peso de la conexión es cuántos comentarios escribió ese autor específico en ese video específico (no cuántos comentarios tiene el video en total).

Como red bipartita, no hay conexiones autor-autor ni video-video en este paso — esas se construyen aparte en la sección 5 (proyecciones).

Nodos totales: 351 (19 videos + 332 autores)

Aristas totales: 343

Es bipartita: True

Tabla de nodos: (351, 14)

Tabla de aristas: (343, 3)

Ejemplo de nodos tipo video:

: 0 | node_id: n8iP75glpmw | tipo: video | titulo: Qué rico come tu diputado | canal: Quorum | categoria: News & Politics | vistas: 11775.0 | n_autores: 128.0 | n_comentarios_video: 161.0 | channel_id: UCE4rsXcgDb6e1-a9iTbWzfg | video_url: https://www.youtube.com/watch?v=n8iP75glpmw | nombre: NaN | n_videos: NaN | n_comentarios_autor: NaN | author_handle: NaN

: 1 | node_id: j43HgwYFKfk | tipo: video | titulo: La cooptación de Walter Mazariegos en la USAC | canal: Quorum | categoria: News & Politics | vistas: 10156.0 | n_autores: 49.0 | n_comentarios_video: 50.0 | channel_id: UCE4rsXcgDb6e1-a9iTbWzfg | video_url: https://www.youtube.com/watch?v=j43HgwYFKfk | nombre: NaN | n_videos: NaN | n_comentarios_autor: NaN | author_handle: NaN

: 2 | node_id: 6W4u8sGEnGM | tipo: video | titulo: Inician los trabajos de recuperación del Puert... | canal: Gobierno de la República de Guatemala | categoria: Entertainment | vistas: 11670.0 | n_autores: 32.0 | n_comentarios_video: 45.0 | channel_id: UC-ZtFBHzgkYFh7whZkuR_Ag | video_url: https://www.youtube.com/watch?v=6W4u8sGEnGM | nombre: NaN | n_videos: NaN | n_comentarios_autor: NaN | author_handle: NaN

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

Ejemplo de nodos tipo autor:

: 19 | node_id: UC-HeUTT6_g-VoiWds2a4H-w | tipo: autor | titulo: NaN | canal: NaN | categoria: NaN | vistas: NaN | n_autores: NaN | n_comentarios_video: NaN | channel_id: NaN | video_url: NaN | nombre: @JorgeMunoz-gd9et | n_videos: 1.0 | n_comentarios_autor: 1.0 | author_handle: /@JorgeMunoz-gd9et

: 20 | node_id: UC-lul5tDYH_oiAMXQH-KaaQ | tipo: autor | titulo: NaN | canal: NaN | categoria: NaN | vistas: NaN | n_autores: NaN | n_comentarios_video: NaN | channel_id: NaN | video_url: NaN | nombre: @AlbertoMancilla-p9h | n_videos: 1.0 | n_comentarios_autor: 1.0 | author_handle: /@AlbertoMancilla-p9h


: 21 | node_id: UC-QOpE7GOxlXcH28b7HbQKA | tipo: autor | titulo: NaN | canal: NaN | categoria: NaN | vistas: NaN | n_autores: NaN | n_comentarios_video: NaN | channel_id: NaN | video_url: NaN | nombre: @mariaalexander427 | n_videos: 1.0 | n_comentarios_autor: 2.0 | author_handle: /@mariaalexander427

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

Ejemplo de aristas:

	source	target	weight
0	n8iP75glpmw	UC-hfX8J5JPJ-dfuakzegMLA	1
1	n8iP75glpmw	UC-jS_kA9w-OmpupXDx156Rg	1
2	n8iP75glpmw	UC-pNP6RMFuLg_-x7Ah_0kEA	1
3	n8iP75glpmw	UC1vr9aaMI2crB0NvwFHUeoQ	1
4	n8iP75glpmw	UC2Y_EHWQKevubk4vOEBBFxw	1

Red bipartita autor-video completa (332 autores, 19 videos, 343 aristas)



La red se ve dominada por dos nodos verdes grandes (los videos más comentados) rodeados de muchos autores conectados solo a ese nodo, y una nube dispersa de pares aislados alrededor de los videos con pocos comentarios. Esto es exactamente lo que esperábamos después de la sección 3: la participación está muy concentrada en pocos videos, así que la red no se ve como una malla uniforme, sino como un puñado de estrellas grandes con muchas puntas cortas.

4.5 Qué significa (y qué no significa) una arista

Una arista entre un autor y un video indica únicamente que ese autor publicó al menos un comentario registrado en ese video, y el peso indica cuántos comentarios distintos publicó ahí (40 de las 343 aristas tienen peso mayor a 1, es decir, hubo 40 casos de un mismo autor comentando varias veces en el mismo video).

Lo que una arista no dice:

- No dice que el autor haya visto el video completo, ni que le haya gustado o esté de acuerdo con su contenido, un comentario puede ser una crítica, una burla o un desacuerdo total.
- No conecta al autor con otros autores del mismo video: dos personas que comentaron el mismo video no necesariamente se leyeron entre sí ni conversaron (recordemos que `reply_count` no identifica quién respondió a quién, así que esta red tampoco lo asume).
- No representa una relación permanente: es una interacción puntual registrada en el momento de la recolección.

En resumen, esta red bipartita muestra dónde se concentró la actividad de comentarios, no relaciones sociales directas entre personas — las coincidencias de participación, sin inferir relaciones personales, son lo que se explora en la sección 5 (proyecciones).

5. Proyecciones de la red

Proyeccion autor-autor:

Nodos (autores): 332

Aristas (pares de autores con al menos un video en comun): 10732

Autores aislados (no comparten ningun video con otro autor): 4

Peso promedio de una arista (videos compartidos): 1.0

Peso maximo de una arista (videos compartidos): 2

Proyeccion video-video:

Nodos (videos): 19

Aristas (pares de videos con al menos un autor en comun): 11

Aristas posibles entre los 19 videos: 171

Densidad de la proyeccion: 0.064

Videos aislados (no comparten autores con ningun otro video): 9

Peso promedio de una arista (autores compartidos): 1.18


Peso maximo de una arista (autores compartidos): 2

5.3 Comparacion de las dos proyecciones

La proyeccion autor-autor queda con 332 nodos y 10732 aristas, una densidad mucho mas alta que cualquier otra red del laboratorio. Esto pasa porque casi todos los autores comentaron en un solo video (solo 9 de 332 comentaron en mas de uno), asi que cada video convierte a todos sus comentaristas en un grupo totalmente conectado entre si. Casi todas las aristas tienen peso 1, es decir esos dos autores comparten exactamente un video, y solo hay 4 autores completamente aislados, que corresponden a videos donde ellos fueron el unico comentarista.

La proyeccion video-video se ve muy distinta. Hay apenas 11 aristas entre los 19 videos con comentarios, sobre 171 pares posibles, con una densidad de 0.064. Nueve de los 19 videos quedan totalmente aislados porque ningun autor que comento ahi volvio a comentar en otro video del conjunto. Las pocas conexiones que existen se explican por esos mismos 9 autores que comentaron en mas de un video.

Cada proyeccion representa un fenomeno distinto. La proyeccion autor-autor muestra coincidencia de audiencia dentro de un mismo video, no una relacion entre personas, que dos autores esten conectados solo dice que comentaron el mismo contenido. La proyeccion video-video muestra si distintos videos atraen al mismo tipo de comentaristas, y en este conjunto de datos esa senal es debil porque la participacion esta muy concentrada por video y casi nadie comento en mas de uno.



En la proyeccion autor-autor se ven varios grupos compactos y muy densos, cada uno formado por los comentaristas de un mismo video, y casi no hay aristas que conecten un grupo con otro porque casi nadie comento en mas de un video. En la proyeccion video-video la mayoría de los videos aparecen sueltos y solo un grupo pequeno se conecta entre si, lo que confirma que la audiencia compartida entre videos es la excepcion y no la regla en estos datos.

6. Topologia y fragmentacion

--- Red bipartita autor-video ---

Nodos: 351 | Aristas: 343

Densidad: 0.0544

Grado medio: 1.95 (min=1, mediana=1.0, max=128)

Nodos con grado 1 (una sola conexion): 327 (93.2%)

Nodos aislados (grado 0): 0

Componentes conexos: 10

Tamano de la componente mas grande: 286 de 351 nodos (81.5%)

Tamanos de los siguientes componentes (top 5): [26, 19, 5, 4, 3]

--- Proyeccion autor-autor ---

Nodos: 332 | Aristas: 10732

Densidad: 0.1953

Grado medio: 64.65 (min=0, mediana=48.0, max=183)

Nodos con grado 1 (una sola conexion): 2 (0.6%)

Nodos aislados (grado 0): 4

Componentes conexos: 10

Tamano de la componente mas grande: 276 de 332 nodos (83.1%)

Tamanos de los siguientes componentes (top 5): [25, 18, 4, 3, 2]

--- Proyeccion video-video ---

Nodos: 19 | Aristas: 11

Densidad: 0.0643

Grado medio: 1.16 (min=0, mediana=1.0, max=4)


Nodos con grado 1 (una sola conexion): 3 (15.8%)

Nodos aislados (grado 0): 9

Componentes conexos: 10

Tamano de la componente mas grande: 10 de 19 nodos (52.6%)

Tamano de los siguientes componentes (top 5): [1, 1, 1, 1, 1]



La red bipartita tiene 351 nodos y solo 343 aristas, con densidad muy baja (0.054) y grado medio de 1.95. Esto es consistente con lo visto en el ejercicio 3, el 93.2% de los nodos tiene grado 1, con la precaución de que este porcentaje mezcla autores de un solo video y videos de un solo autor, mientras que unos pocos nodos de video concentran decenas o incluso 128 conexiones, el caso del video mas comentado del conjunto. La red no esta completamente conectada, se divide en 10 componentes, pero uno solo, con 286 de los 351 nodos, un 81.5%, concentra casi toda la estructura. Los otros 9 componentes son videos que quedaron aislados junto con sus propios comentaristas, sin compartir ningun autor con el resto de la red.

Las dos proyecciones heredan la misma fragmentacion en 10 componentes, porque estan construidas sobre la misma base bipartita. En la proyeccion autor-autor el grado medio es mucho mas alto, 64.65, porque cada video convierte a sus comentaristas en un grupo totalmente conectado entre si, solo 2 autores tienen grado 1 y apenas 4 quedan aislados. En la proyeccion video-video la mayoria de los nodos tiene grado 0 o 1, 9 aislados y 3 con grado 1, y solo 10 de los 19 videos forman la componente gigante, el resto no comparte ningun autor con ningun otro video.

Transitividad global (nx.transitivity):

Red bipartita (valor trivial, una red bipartita no puede tener triangulos): 0

Proyeccion autor-autor: 0.984

Proyeccion video-video: 0.3158

Coefficiente de clustering promedio (nx.average_clustering):

Proyeccion autor-autor: 0.972

Proyeccion video-video: 0.1491

Coefficiente de clustering bipartito (lado autores): 0.9423

Red bipartita: componente gigante de 286 nodos, distancia promedio 4.72, diametro 12

Proyeccion autor-autor: componente gigante de 276 nodos, distancia promedio 2.36, diametro 6

Proyeccion video-video: componente gigante de 10 nodos, distancia promedio 2.49, diametro 5

La transitividad de la red bipartita es 0 por definicion, una red bipartita no puede tener triangulos porque las aristas solo conectan autores con videos, nunca autores entre si ni videos entre si. Por eso se calcula en su lugar el coeficiente de clustering bipartito, que da 0.9423 para el lado de los autores. Con el modo predeterminado dot de NetworkX se promedia el Jaccard de vecindarios entre autores a distancia dos. Dos hojas de la misma estrella tienen exactamente el mismo vecino y similitud 1, aun sin ciclos de cuatro. Por ello el valor alto describe vecindarios semejantes, no conversaciones, triángulos ni evidencia independiente de cohesión social.

En la proyeccion autor-autor la transitividad, 0.984, y el clustering promedio, 0.972, tambien son muy altos, porque cada video comentado forma un grupo de autores donde todos estan conectados con todos, asi que casi cualquier trio de autores que coincidio en el mismo video forma un triangulo. La proyeccion video-video tiene valores mucho mas bajos y dispares, transitividad 0.3158 y clustering promedio 0.1491, porque son solo 19 nodos con pocas conexiones y la poca estructura que existe depende de unos cuantos autores puente.

Como medida adicional de cohesion, dentro de la componente gigante de cada red la distancia promedio y el diametro son bajos, 2.36 y 6 para la proyeccion autor-autor, 2.49 y 5 para la video-video, y 4.72 y 12 para la bipartita, mas alta porque ahi cada paso alterna entre autor y video y se necesitan el doble de saltos para llegar al mismo lugar. En conjunto esto muestra una red donde los subgrupos internos estan muy cohesionados, pero esa cohesion no se extiende a toda la red porque son subgrupos casi independientes entre si.

Videos que no aparecen en la red porque no tienen comentarios en este conjunto: 274 de 293 (93.5%)

Esto no es aislamiento observado, es un límite de cobertura: esos videos pudieron tener comentarios reales en YouTube que el proceso de recolección no capturó.

Autores presentes en la red pero sin ningún autor conectado (aislamiento observado): 4 de 332

Videos presentes en la red pero sin ningún video conectado (aislamiento observado): 9 de 19

Videos aislados en la proyección video-video:

Plan 2032 Ciudad de Guatemala | autores en ese video: 25

EE.UU. envía a mexicanos deportados a Guatemala antes de su regreso a México | Noticias Telemundo | autores en ese video: 18

I'x K'at: el primer equipo guatemalteco de pelota maya, conformado únicamente por mujeres. | autores en ese video: 4

10 Preguntas a un año del Paro Nacional | autores en ese video: 3

Noticiero en Directo 1 pm, 28 de Agosto de 2026 | autores en ese video: 2

Cruzando la ciudad a puro Transmetro | autores en ese video: 1

SHAI WA: la vecina queer de Casa Presidencial | autores en ese video: 1

¿Quiénes pagan más en Centroamérica? | autores en ese video: 1

Edén por Salud: empleo inclusivo para personas con discapacidad en Antigua | Super - Episodio 2 | autores en ese video: 1

Es importante distinguir dos tipos de ausencia en esta red. La primera es ausencia de datos, 274 de los 293 videos del conjunto, un 93.5%, ni siquiera aparecen como nodo porque no tuvieron ningún comentario en este conjunto de datos. Eso no significa que esos videos no tengan comentarios en YouTube, solo que el proceso de recolección no los capturó, así que no se puede interpretar como aislamiento real.

La segunda es aislamiento observado, nodos que si están en la red pero sin ninguna conexión en la proyección correspondiente. Son 4 autores en la proyección autor-autor y 9 videos en la proyección video-video. Los 9 videos aislados son justamente los que tienen menos comentaristas, entre 1 y 25 autores, varios con un único comentarista, y ninguno de esos comentaristas volvió a comentar en otro video del conjunto, por eso cada uno de esos videos queda como un grupo periférico separado del resto de la red.

En conjunto, la topología de estas redes muestra una estructura de islas densas más que una malla conectada. La red bipartita y sus dos proyecciones comparten la misma fragmentación de fondo, en 10 componentes, porque nacen de los mismos 19 videos comentados. Los pocos videos con muchos comentaristas y con autores que también comentaron en otro lado forman una componente gigante que concentra alrededor del 80% de los nodos, mientras que los videos con comentaristas exclusivos quedan como islas pequeñas y aisladas.

Dentro de cada isla la cohesión es altísima, con clustering y transitividad cercanos a 1, porque comentar el mismo video conecta automáticamente a todos los comentaristas entre sí. Pero esa cohesión es local, no global, no dice que la comunidad de comentaristas de este conjunto esté bien conectada en su totalidad, dice que existen varios grupos chicos y muy compactos que casi no se tocan entre sí. Esto es coherente con lo visto en el ejercicio 3, la participación está concentrada en pocos videos y casi nadie comenta en más de uno, y sienta la base para el ejercicio 7, donde se espera que la detección de comunidades recupere aproximadamente esta misma división en subgrupos.

7. Comunidades

7.1 Selección de la red y justificación

Se usa la red bipartita autor-video (B) para detectar comunidades, en vez de una de las proyecciones. La razón es que las proyecciones se construyen a partir de conteos derivados (videos compartidos, autores compartidos) y ya vimos en los ejercicios 5 y 6 que eso infla artificialmente la densidad, por ejemplo la proyección autor-autor queda con clustering casi perfecto solo porque cada video convierte a sus comentaristas en un clan cerrado. La red bipartita en cambio conserva la estructura original de participación, quien comentó en qué video y cuántas veces, que es justo el dato que queremos agrupar en comunidades.

Número de comunidades encontradas: 17

Modularidad: 0.7774


Tamaños de las comunidades: [126, 48, 32, 31, 26, 19, 19, 14, 8, 8, 5, 4, 3, 2, 2, 2, 2]

Louvain encontró 17 comunidades con una modularidad de 0.7774, para esta partición y este modelo nulo. No existe un umbral universal de 0.3 que valide comunidades: el valor depende de grados, componentes, pesos y resolución. Louvain

utiliza modularidad ordinaria, no un modelo nulo bipartito; sin contraste aleatorizado ni análisis de estabilidad se interpreta como descripción exploratoria, no validación de grupos sociales. Los tamanos van desde 126 nodos en la comunidad mas grande hasta comunidades de apenas 2 nodos, con una caída pronunciada, solo dos comunidades superan los 40 nodos, 126 y 48, y casi la mitad de las 17 comunidades tiene 5 nodos o menos.

El numero de comunidades, 17, es mayor que el numero de componentes conexos del ejercicio 6, que fueron 10. Esto pasa porque la componente gigante de 286 nodos, aunque esta toda conectada, en realidad tiene subgrupos mucho mas densos entre si que con el resto de la componente, y Louvain los separo en comunidades distintas aunque tecnicamente pertenezcan al mismo componente conectado. En la practica, cada comunidad grande termina coincidiendo casi exactamente con los comentaristas de un solo video o de un grupo pequeno de videos del mismo canal.

Comunidades detectadas con Louvain (17 comunidades, modularidad 0.777)



En la visualizacion se ve claramente que cada comunidad grande se forma alrededor de un solo video, el nodo de video queda en el centro rodeado de sus propios comentaristas del mismo color, casi sin mezclarse con los colores de las demas comunidades. Esto confirma la lectura del ejercicio 6, la red no es una malla conectada sino un conjunto de grupos casi independientes, y Louvain simplemente les puso una etiqueta formal a esos grupos que ya se intuian en la estructura.

Comentarios entrantes de autores externos: 3

Comentarios salientes a videos externos: 1

--- Comunidad 0 ---

Nodos: 126 (1 videos, 125 autores)

Comentarios internos: 158

Videos: ['Qué rico come tu diputado']

Canales: ['Quorum']

Categorías: ['News & Politics']

Palabras mas frecuentes: [('pueblo', 49), ('diputado', 48), ('pagar', 35), ('dinero', 27), ('trabajo', 21), ('q', 21), ('sueldo', 20), ('almuerzo', 17)]

Ejemplos de comentarios (texto original):

- Lleven su lonchera, sacrifíquense un poco. Y reintevren ese dinero. O están robando.
- LADRONES !!!!
- Tiene un poquito de oro y no habla como resolver los problemas .

Comentarios entrantes de autores externos: 2

Comentarios salientes a videos externos: 1

--- Comunidad 1 ---

Nodos: 48 (1 videos, 47 autores)

Comentarios internos: 48

Videos: ['La cooptación de Walter Mazariegos en la USAC']

Canales: ['Quorum']

Categorías: ['News & Politics']

Palabras mas frecuentes: [('usac', 9), ('corrupto', 9), ('estudiante', 7), ('universidad', 6), ('excelente', 5), ('información', 5), ('universitario', 4), ('seguir', 4)]

Ejemplos de comentarios (texto original):

- Me dejaron con ganas de demandar la ilegalidad de las reuniones virtuales, esto no es una maquila
- Veremos a este mafioso de Mazariegos en la cárcel y un buen tiempo en la sombra.
- Denle golpe universitario (de estado). Lo puede hacer el CSU?

Comentarios entrantes de autores externos: 0

Comentarios salientes a videos externos: 2

--- Comunidad 7 ---

Nodos: 32 (3 videos, 29 autores)

Comentarios internos: 34

Videos: ['Internet: escoger el menos malo', 'Caminar en una ciudad hecha para carros', 'Arroz con pollo a la MONOPOLIO']

Canales: ['Quorum']

Categorías: ['News & Politics']

Palabras mas frecuentes: [('excelente', 11), ('empresa', 9), ('internet', 7), ('ley', 7), ('seguir', 5), ('servicio', 5), ('país', 5), ('pequeño', 4)]

Ejemplos de comentarios (texto original):

- buenisima investigacion :hand-purple-blue-peace::hand-purple-blue-peace::hand-purple-blue-peace:
- Otro pequeño truco es que tenés un plan mensual de Gb y redes ilimitadas y luego te mandan mensaje que consumiste el 95% de tu plan y ahí vi
- Este video debe llegar a muchas personas, es muy buena información

Los perfiles anteriores usan exclusivamente comentarios internos : tanto el autor como el video deben pertenecer a la misma comunidad. Se reporta por separado actividad entrante de autores externos y saliente hacia videos externos. Por ello el número de autores asignados no debe confundirse con todos los comentaristas de los videos asignados. Los identificadores de comunidad son los originales de Louvain (base cero), no su posición en el ranking por tamaño.

Las tres comunidades mayores se relacionan con Quorum: remuneración de diputados, el caso de la USAC y servicios de internet, monopolios y movilidad urbana. Estas etiquetas temáticas se apoyan en títulos y frecuencias de palabras, no en source_query como verdad temática. La sección 9 integra la misma selección interna con sentimiento y cuantifica los resultados; los ejemplos cualitativos anteriores no constituyen validación manual del modelo.

8. Nodos centrales y participantes puente

8.1 Medidas y significado de los pesos

Se calculan grado, fuerza, intermediación y cercanía sobre la bipartita. El grado de un autor cuenta videos distintos; el grado de un video , autores distintos. La fuerza suma comentarios y mide recurrencia, no diversidad. La intermediación mide la fracción de caminos mínimos que atraviesa el nodo (se excluyen extremos); la cercanía usa el ajuste de Wasserman–Faust para componentes desconectados. Se comparan rankings por tipo, no autores contra videos. No se interpreta centralidad como influencia causal.

Los caminos son no ponderados : cada relación observada cuesta un salto. Usar directamente la frecuencia de comentarios como distancia haría más lejanas las relaciones intensas. Si se adoptaran caminos ponderados, habría que justificar una transformación como $\text{distance} = 1 / \text{weight}$; aquí no se supone que la repetición facilite difusión. Véase NetworkX: intermediación y cercanía .

8.2 Autores recurrentes y diversidad; videos con alcance observado

: 117 | node_id: UCHTGCgY2l-DQJlVIA_cpa_Q | nombre: @virgiliogarcia3039 | comment_count: 3 | distinct_videos: 2 | distinct_channels: 2 | extra_comments: 1 | betweenness: 0.231584 | closeness: 0.252801 | articulation: True | component_increase: 1

: 295 | node_id: UCpsKOkt5iWTbenzeuq7dsmQ | nombre: @inge_vergueta | comment_count: 3 | distinct_videos: 3 | distinct_channels: 1 | extra_comments: 0 | betweenness: 0.218076 | closeness: 0.265528 | articulation: True | component_increase: 1

: 349 | node_id: UCzZ6dDCEsLMXbc5pCFXlprw | nombre: @josegil3813 | comment_count: 2 | distinct_videos: 2 | distinct_channels: 1 | extra_comments: 0 | betweenness: 0.176832 | closeness: 0.182733 | articulation: True | component_increase: 1

: 344 | node_id: UCylqlpsh8ENNM1LqgQ1KbxA | nombre: @Jel.Awesh.M | comment_count: 3 | distinct_videos: 2 | distinct_channels: 1 | extra_comments: 1 | betweenness: 0.089153 | closeness: 0.247940 | articulation: False | component_increase: 0

: 326 | node_id: UCvcu1kR8xMYy_I1Ty-2mV2Q | nombre: @hashojea7348 | comment_count: 4 | distinct_videos: 3 | distinct_channels: 1 | extra_comments: 1 | betweenness: 0.059705 | closeness: 0.173188 | articulation: True | component_increase: 1

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

: 0 | node_id: n8iP75glpmw | titulo: Qué rico come tu diputado | degree: 128 | strength: 161 | shared_audience_videos: 4 | betweenness: 0.565698 | closeness: 0.304556 | articulation: True | component_increase: 126 | projection_articulation: True

: 4 | node_id: PjmxCj-a9Hg | titulo: Conferencia de Prensa del Gobierno de Guatemala... | degree: 19 | strength: 25 | shared_audience_videos: 2 | betweenness: 0.244028 | closeness: 0.215680 | articulation: True | component_increase: 18 | projection_articulation: True

: 1 | node_id: j43HgwYFKfk | titulo: La cooptación de Walter Mazariégo en la USAC | degree: 49 | strength: 50 | shared_audience_videos: 3 | betweenness: 0.227474 | closeness: 0.221442 | articulation: True | component_increase: 47 | projection_articulation: True

: 2 | node_id: 6W4u8sGEnGM | titulo: Inician los trabajos de recuperación del Puent... | degree: 32 | strength: 45 | shared_audience_videos: 2 | betweenness: 0.187622 | closeness: 0.158302 | articulation: True | component_increase: 31 | projection_articulation: True

: 8 | node_id: ndAZjHqzzT8 | titulo: Internet: escoger el menos malo | degree: 10 | strength: 12 | shared_audience_videos: 4 | betweenness: 0.128293 | closeness: 0.211358 | articulation: True | component_increase: 8 | projection_articulation: True

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

Autores con más de un comentario: 46

Autores multivideo: 9

Autores multicanal: 4

Mayor recurrencia por conteo:

: 260 | node_id: UCi2KiZq63sRq8Mfbcp-MelQ | nombre: @eugeneramirez4405 | comment_count: 6 | distinct_videos: 1 | distinct_channels: 1 | extra_comments: 5 | betweenness: 0.0 | closeness: 0.026449 | articulation: False | component_increase: 0


: 341 | node_id: UCyJhqmMbsvjpoarBBStA2kg | nombre: @Murmullodelbarrio | comment_count: 6 | distinct_videos: 1 | distinct_channels: 1 | extra_comments: 5 | betweenness: 0.0 | closeness: 0.132612 | articulation: False | component_increase: 0

: 52 | node_id: UC5H8ASmMC9WrURmzeB4ySog | nombre: @ManuelEdran | comment_count: 5 | distinct_videos: 1 | distinct_channels: 1 | extra_comments: 4 | betweenness: 0.0 | closeness: 0.221866 | articulation: False | component_increase: 0

: 183 | node_id: UCV3fr-YOixFKCZBbJP1-X4w | nombre: @albertoshernandez5251 | comment_count: 5 | distinct_videos: 1 | distinct_channels: 1 | extra_comments: 4 | betweenness: 0.0 | closeness: 0.132612 | articulation: False | component_increase: 0

: 76 | node_id: UC9vMq1YF-e7C-VO0SHkbUTA | nombre: @ErvinLeonardoCarreraLatín | comment_count: 4 | distinct_videos: 1 | distinct_channels: 1 | extra_comments: 3 | betweenness: 0.0 | closeness: 0.221866 | articulation: False | component_increase: 0

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.



8.3 Prueba de articulación y límites de la interpretación

Un punto de articulación es un nodo cuya eliminación aumenta el número de componentes, no simplemente un nodo de grado alto ni un autor multicanal. La tabla siguiente verifica cada candidato eliminándolo de una copia de la red. En un video, la fragmentación puede consistir en dejar autores de grado uno aislados: eso no prueba que conecte contenidos diferentes. La articulación en la proyección video-video se reporta como criterio adicional para esa segunda interpretación.

Componentes iniciales: 10

Autores articuladores (identificador y aumento de componentes):

	nombre	distinct_videos	distinct_channels	betweenness	component_increase
117	@virgiliogarcia3039	2	2	0.231584	1
295	@inge_vergueta	3	1	0.218076	1
349	@josegil3813	2	1	0.176832	1
326	@hashojea7348	3	1	0.059705	1
269	@franciscoflores3120	2	2	0.057896	1
230	@MarcosCarillo-b1r	2	2	0.031862	1
306	@moisesvaldez4043	2	2	0.031862	1

Videos articuladores en la bipartita:

	título	degree	component_increase	projection_articulation
0	Qué rico come tu diputado	128	126	True
4	Conferencia de Prensa del Gobierno de Guatemal...	19	18	True
1	La cooptación de Walter Mazariegos en la USAC	49	47	True
2	Inician los trabajos de recuperación del Puent...	32	31	True
8	Internet: escoger el menos malo	10	8	True
6	Arroz con pollo a la MONOPOLIO	16	14	False
7	Capturan a presuntos delincuentes disfrazados ...	13	12	False
10	Bloqueos en Guatemala este 31 de agosto por al...	7	6	False

	titulo	degree	component_increase	projection_articulation
9	Capturan a ladrón que había quedado grabado mi...	7	6	False
11	Caminar en una ciudad hecha para carros	6	5	False
3	Plan 2032 Ciudad de Guatemala	25	24	False
5	EE.UU. envía a mexicanos deportados a Guatemal...	18	17	False
12	l'x K'at: el primer equipo guatemalteco de pel...	4	3	False
13	10 Preguntas a un año del Paro Nacional	3	2	False
14	Noticiero en Directo 1 pm, 28 de Agosto de 2026	2	1	False

	author_channel_id	author_name	video_id	channel_id	channel_name	title
0	UCdFlugHJJJa4l3YqWuNRmvXw	@MarcosCarillo-b1r	j43HgwYFKfk	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	La cooptación de Walter Mazariegos en la USAC
1	UCvcu1kR8xMYy_l1Ty-2mV2Q	@hashojea7348	yLZS3JiEBg8	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Arroz con pollo a la MONOPOLIO
2	UCjZgFEowMBrsjodqfovzdKw	@franciscoflores3120	6W4u8sGEnGM	UC-ZtFBHhgkYFh7whZkuR_Ag	Gobierno de la República de Guatemala	Inician los trabajos de recuperación del Puent...
3	UCdFlugHJJJa4l3YqWuNRmvXw	@MarcosCarillo-b1r	is3Mk5oC19g	UCT5Dw7ePnn0AqPqRF8Xpjkw	TN23 Guatemala	Capturan a ladrón que había quedado grabado mi...
4	UCvcu1kR8xMYy_l1Ty-2mV2Q	@hashojea7348	WIUZtiFLRw	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Caminar en una ciudad hecha para carros
5	UCpsKOKt5iWTbenzeuq7dsmQ	@inge_vergueta	ndAZjHqzzT8	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Internet: escoger el menos malo
6	UCzZ6dDCEsLMXbc5pCFXlprw	@josegil3813	6W4u8sGEnGM	UC-ZtFBHhgkYFh7whZkuR_Ag	Gobierno de la República de Guatemala	Inician los trabajos de recuperación del Puent...
7	UCvcu1kR8xMYy_l1Ty-2mV2Q	@hashojea7348	ndAZjHqzzT8	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Internet: escoger el menos malo
8	UCpsKOKt5iWTbenzeuq7dsmQ	@inge_vergueta	j43HgwYFKfk	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	La cooptación de Walter Mazariegos en la USAC
9	UCHTGCgY2l-DQJlviA_cpa_Q	@virgiliogarcia3039	n8iP75glpmw	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Qué rico come tu diputado
10	UCsUCN0Yq_UyTvKjOJLmNrnQ	@moisesvaldez4043	n8iP75glpmw	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Qué rico come tu diputado
11	UCjZgFEowMBrsjodqfovzdKw	@franciscoflores3120	06mFNPU0aB8	UCVpSRoZgngfSL03Nlbtq9A	Noti7	Capturan a presuntos delincuentes disfrazados ...
12	UCpsKOKt5iWTbenzeuq7dsmQ	@inge_vergueta	n8iP75glpmw	UCE4rsXcgDb6e1-a9iTbWzfg	Quorum	Qué rico come tu diputado
13	UCsUCN0Yq_UyTvKjOJLmNrnQ	@moisesvaldez4043	b_Hkrkl3adA	UCEepOY2svuxbsJ-zsAPT9Fg	PrensaLibreOficial	Bloqueos en Guatemala este 31 de agosto por al...
14	UCzZ6dDCEsLMXbc5pCFXlprw	@josegil3813	PjmxCj-a9Hg	UC-ZtFBHhgkYFh7whZkuR_Ag	Gobierno de la República de Guatemala	Conferencia de Prensa del Gobierno de Guatemal...

	author_channel_id	author_name	video_id	channel_id	channel_name	title
15	UCHTGCgY2l-DQJvIA_cpa_Q	@virgiliogarcia3039	PjmxCj-a9Hg	UC-ZtFBHzgkYFh7whZkuR_Ag	Gobierno de la República de Guatemala	Conferencia de Prensa del Gobierno de Guatemal...

Lectura: @virgiliogarcia3039 presenta la mayor intermediación entre autores (0.2316); participa en 2 videos y 2 canales. Hay 7 autores articuladores frente a 9 autores multivideo. El video con mayor intermediación es Qué rico come tu diputado , con 128 autores y 161 comentarios. 15 videos son articulaciones bipartitas, pero solo 5 lo son en la proyección de videos. La evidencia indica coincidencia de participación, no que estas cuentas comuniquen mensajes entre audiencias.

9. Análisis de contenido y sentimiento

9.1 Modelo español y reproducibilidad

Se usa pysentimiento/RobERTuito , ajustado con aproximadamente 5 000 tweets de TASS 2020 de distintas variedades de español. Es más pertinente para texto social en español que un léxico inglés o una lista de palabras elegida ad hoc. La ficha reporta macro-F1 de 0.705 ± 0.003 en su evaluación, no en estos comentarios de YouTube . No se ha realizado validación manual local y no se atribuye esa exactitud a esta muestra.

- Modelo: pysentimiento/robertuito-sentiment-analysis ; revisión inmutable a2cc0f67ebd705c55191e25a05ba23d885fcc09b .
- Entrada: texto_original preservado, nunca texto_limpio . Una columna aparte guarda el resultado de preprocess_tweet(lang='es') de pysentimiento 0.7.3 (menciones, enlaces, hashtags, repeticiones, emojis y risas). El original no se modifica. Esta normalización puede perder matices, incluso de emojis.
- Inferencia local en CPU, cuatro hilos, lotes de 16, evaluación sin gradientes; pesos safetensors. Se descarga aproximadamente 435 MB la primera vez, además de dependencias, y se usa la caché de Hugging Face después. No se envían comentarios a una API.
- Límite de 128 tokens como el analizador de pysentimiento; se registra longitud y truncamiento. Se predice NEG, NEU o POS por argmax; P(POS)-P(NEG) es un índice descriptivo entre -1 y 1, no una escala validada de intensidad.
- Se auditan probabilidades, entradas vacías, truncamiento y confianza máxima menor que 0.60. Este umbral es una bandera exploratoria, no garantía de error/acierto; las probabilidades no están calibradas en este dominio. Los textos vacíos no se fuerzan a neutral.

Referencias: ficha del modelo , Pérez et al., RoBERTuito, 2022 , pysentimiento . Revisar licencias de modelos y corpus antes de reutilizar fuera del contexto académico.

```
/home/jonialen/Documents/uvvg/s8/data/lab6-ds/.venv/lib/python3.11/site-packages/tqdm/auto.py:21: TqdmWarning: IPProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs.io/en/stable/use
```

```
from .autonotebook import tqdm as notebook_tqdm
```

Inferencia y carga del modelo: 36.7 segundos

Modelo: pysentimiento/robertuito-sentiment-analysis revisión: a2cc0f67ebd705c55191e25a05ba23d885fcc09b

Cobertura: {'classified': 406}

Etiquetas: {'NEG': 249, 'POS': 79, 'NEU': 78}

Comentarios truncados: 11

Confianza menor que 0.60: 69

```
: 0 | comment_id: Ugw-J65a1iYL9hghELh4AaABAg | texto_original: Ese corrupto amigo de la vieja fiscal los teng... | sentiment: NEG | p_NEG: 0.807787 | p_NEU: 0.146285 | p_POS: 0.045928 | token_count: 18 | truncated: False | confidence: 0.807787
```


```
: 1 | comment_id: Ugw-ZT9t9wU2V-tCaUZ4AaABAg | texto_original: Están jóvenes porque no buscan un trabajo, tu... | sentiment: NEG | p_NEG: 0.965087 | p_NEU: 0.029080 | p_POS: 0.005832 | token_count: 38 | truncated: False | confidence: 0.965087
```

```
: 2 | comment_id: Ugw0xaOb2CYXXoudtwJ4AaABAg | texto_original: Me dejaron con ganas de demandar la ilegalidad... | sentiment: NEG | p_NEG: 0.971377 | p_NEU: 0.025967 | p_POS: 0.002656 | token_count: 22 | truncated: False | confidence: 0.971377
```

```
: 3 | comment_id: Ugw0xgUc2ISpBr5_T654AaABAg | texto_original: Veremos a este mafioso de Mazariegos en la cár... | sentiment: NEG | p_NEG: 0.701865 | p_NEU: 0.267649 | p_POS: 0.030487 | token_count: 22 | truncated: False | confidence: 0.701865
```


: 4 | comment_id: Ugw1ZzA21njWhaqQQTh4AaABAg | texto_original: eso es para que salga de USA por su propio pie... | sentiment: NEG | p_NEG: 0.745216 | p_NEU: 0.232894 | p_POS: 0.021890 | token_count: 22 | truncated: False | confidence: 0.745216

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.



9.2 Comparaciones por video, canal y comunidad

Se muestran todos los tamaños; se grafican comparaciones solo con n clasificado ≥ 10 , criterio descriptivo fijado para evitar porcentajes dominados por una o dos filas, no umbral de significación. La tabla completa conserva muestras pequeñas. La unidad es el comentario, no el autor: la recurrencia produce dependencia y los intervalos binomiales ingenuos no serían apropiados. No se realizan pruebas de significación ni afirmaciones causales.

Las comunidades mantienen el alcance interno de 7.5; los comentarios cruzados permanecen en resultados por video/canal y en una auditoría separada, pero no se mezclan con los perfiles internos. Un comentario negativo puede criticar al personaje del video y elogiar al canal; el modelo predice tono general sin identificar ese destinatario. Ironía, negación, lenguaje político local, textos mixtos, truncamiento y cambio de dominio Twitter–YouTube limitan la lectura.

	title	n_total	NEG	NEU	POS	mean_score	small_sample
0	Qué rico come tu diputado	161	130	23	8	-0.670333	False
1	La cooptación de Walter Mazariegos en la USAC	50	29	11	10	-0.341222	False
2	Inician los trabajos de recuperación del Puent...	45	18	14	13	-0.108989	False
3	Plan 2032 Ciudad de Guatemala	25	2	3	20	0.605101	False

	title	n_total	NEG	NEU	POS	mean_score	small_sample
4	Conferencia de Prensa del Gobierno de Guatemala...	25	17	4	4	-0.421545	False
5	EE.UU. envía a mexicanos deportados a Guatemala...	25	16	6	3	-0.462330	False
6	Arroz con pollo a la MONOPOLIO	16	9	2	5	-0.237511	False
7	Capturan a presuntos delincuentes disfrazados ...	14	4	7	3	-0.176527	False
8	Internet: escoger el menos malo	12	4	3	5	0.033241	False
9	Capturan a ladrón que había quedado grabado mi...	7	6	1	0	-0.621819	True
10	Bloqueos en Guatemala este 31 de agosto por al...	7	6	1	0	-0.758970	True
11	Caminar en una ciudad hecha para carros	6	4	2	0	-0.537878	True
12	l'x K'at: el primer equipo guatemalteco de pel...	4	1	0	3	0.466570	True
13	10 Preguntas a un año del Paro Nacional	3	1	0	2	0.157347	True
14	Noticiero en Directo 1 pm, 28 de Agosto de 2026	2	1	1	0	-0.519329	True
15	Cruzando la ciudad a puro Transmetro	1	1	0	0	-0.894237	True
16	SHAI WA: la vecina queer de Casa Presidencial	1	0	0	1	0.971551	True
17	¿Quiénes pagan más en Centroamérica?	1	0	0	1	0.717856	True
18	Edén por Salud: empleo inclusivo para personas. ...	1	0	0	1	0.523673	True

	channel_name	n_total	NEG	NEU	POS	mean_score	small_sample
0	Quorum	256	179	41	36	-0.499828	False
1	Gobierno de la República de Guatemala	70	35	18	17	-0.220616	False

	channel_name	n_total	NEG	NEU	POS	mean_score	small_sample
2	Noticias Telemundo	25	16	6	3	-0.462330	False
3	Municipalidad de Guatemala	25	2	3	20	0.605101	False
4	Noti7	14	4	7	3	-0.176527	False
5	PrensaLibreOficial	7	6	1	0	-0.758970	True
6	TN23 Guatemala	7	6	1	0	-0.621819	True
7	Noticiero Guatevisión 13 Hrs.	2	1	1	0	-0.519329	True

: 0 | community: 0 | nodes: 126 | assigned_authors: 125 | assigned_videos: 1 | internal_comments: 158 | incoming_comments: 3 | outgoing_comments: 1 | NEG: 127 | NEU: 23 | POS: 8 | small_sample: False


: 1 | community: 1 | nodes: 48 | assigned_authors: 47 | assigned_videos: 1 | internal_comments: 48 | incoming_comments: 2 | outgoing_comments: 1 | NEG: 28 | NEU: 10 | POS: 10 | small_sample: False

: 2 | community: 7 | nodes: 32 | assigned_authors: 29 | assigned_videos: 3 | internal_comments: 34 | incoming_comments: 0 | outgoing_comments: 2 | NEG: 17 | NEU: 7 | POS: 10 | small_sample: False

: 3 | community: 2 | nodes: 31 | assigned_authors: 30 | assigned_videos: 1 | internal_comments: 43 | incoming_comments: 2 | outgoing_comments: 0 | NEG: 17 | NEU: 13 | POS: 13 | small_sample: False

: 4 | community: 3 | nodes: 26 | assigned_authors: 25 | assigned_videos: 1 | internal_comments: 25 | incoming_comments: 0 | outgoing_comments: 0 | NEG: 2 | NEU: 3 | POS: 20 | small_sample: False

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.



Cruce de fronteras comunitarias: 8 comentarios

Sensibilidad: distribución sin textos truncados ni confianza < 0.60 (no reemplaza el resultado principal):

sentiment	NEG	NEU	POS
row_0			
False	225	38	64
True	24	40	15

Comunidad 0: 126 nodos

Contenido: Qué rico come tu diputado. Canales: Quorum. Participación interna: 125 autores asignados, 125 autores con comentarios internos y 158 comentarios. Hay 3 comentarios entrantes y 1 salientes.

Términos frecuentes: pueblo:49, diputado:48, pagar:35, dinero:27, trabajo:21, sueldo:20, almuerzo:17, trabajar:16.

Sentimiento automático interno (n=158): NEG 127 (80.4%), NEU 23 (14.6%), POS 8 (5.1%); índice medio -0.666. Estos conteos describen tono predicho, no apoyo o rechazo al canal ni opinión de todos sus espectadores.

Comunidad 1: 48 nodos

Contenido: La cooptación de Walter Mazariegos en la USAC. Canales: Quorum. Participación interna: 47 autores asignados, 47 autores con comentarios internos y 48 comentarios. Hay 2 comentarios entrantes y 1 salientes.

Términos frecuentes: usac:9, corrupto:9, estudiante:7, universidad:6, excelente:5, información:5, universitario:4, seguir:4.

Sentimiento automático interno (n=48): NEG 28 (58.3%), NEU 10 (20.8%), POS 10 (20.8%); índice medio -0.341. Estos conteos describen tono predicho, no apoyo o rechazo al canal ni opinión de todos sus espectadores.

Comunidad 7: 32 nodos

Contenido: Caminar en una ciudad hecha para carros | Internet: escoger el menos malo | Arroz con pollo a la MONOPOLIO. Canales: Quorum. Participación interna: 29 autores asignados, 29 autores con comentarios internos y 34 comentarios. Hay 0 comentarios entrantes y 2 salientes.

Términos frecuentes: excelente:11, empresa:9, internet:7, ley:7, seguir:5, servicio:5, país:5, pequeño:4.

Sentimiento automático interno (n=34): NEG 17 (50.0%), NEU 7 (20.6%), POS 10 (29.4%); índice medio -0.195. Estos conteos describen tono predicho, no apoyo o rechazo al canal ni opinión de todos sus espectadores.

Síntesis de 9.3 y respuesta a 3.5: entre canales con $n \geq 10$, el menor índice medio corresponde a Quorum (-0.500, $n=256$) y el mayor a Municipalidad de Guatemala (0.605, $n=25$). Las diferencias pueden reflejar contenido, selección de comentarios y autores recurrentes, no un efecto del canal. Los perfiles anteriores integran temas y sentimiento en las tres comunidades mayores.

10. Interpretación, limitaciones y conclusiones

10.1–10.3 Alcance de la evidencia

Descripción: contamos registros, relaciones autor-video, coparticipación y etiquetas automáticas. Asociación: contrastamos vistas/comentarios y tono entre grupos de esta muestra; las correlaciones no identifican causas. Inferencia: no se estiman opiniones poblacionales, influencia de cuentas, circulación de información ni efectos de canales porque faltan diseño probabilístico, secuencia temporal y relaciones de respuesta verificadas.

Limitaciones mínimas y adicionales:

- Cobertura de comentarios: solo 19 de 293 videos tienen comentarios recolectados; los 274 restantes no son videos sin audiencia ni comentarios reales. La bipartita describe únicamente los nodos con participación observada; una tabla de cobertura conserva los 293 videos.
- Selección por consultas y fuentes: `source_query`, `source_group` y `query_hits` documentan recuperación, no temas verdaderos ni probabilidades de inclusión. El grupo `oficial_gov` sin comentarios capturados no demuestra comentarios deshabilitados.
- Fechas relativas: no se convierten “hace N días” en fechas exactas sin instante de recolección; no se reconstruye evolución temporal con estos datos.
- Conteos instantáneos: vistas, likes y respuestas son capturas parciales. Las diferencias entre vistas textuales y numéricas no prueban orden de extracción. Likes ausentes imputados a cero son un supuesto auditado, no ceros conocidos.

- Ausencia de relaciones explícitas entre autores: `reply_count` no identifica quién respondió a quién; un punto en `comment_id` no establece genealogía. Las proyecciones no representan amistad, conversación, aprobación ni difusión.
- Concentración: unos pocos videos y canales dominan la muestra. Repeticiones del mismo autor no son observaciones independientes; las predicciones globales ponderan más a quienes comentan más.
- Redes y comunidades: la proyección infla cohesión por construcción; la modularidad ordinaria no usa un modelo nulo bipartito ni se valida por un umbral universal. Semilla fija da reproducibilidad, no demuestra estabilidad de Louvain. Articulación es vulnerabilidad estructural de esta muestra, no influencia social comprobada.
- Sentimiento: modelo de tweets aplicado a YouTube sin validación manual local; puede fallar con ironía, guatemaltequismos, destinatarios múltiples o texto truncado. No se comparan muestras pequeñas como si fueran robustas y no se infiere aprobación política a partir de NEG/POS.

10.4 Conclusiones integradas

- Participación concentrada: 406 comentarios de 332 autores cubren 19/293 videos. El video más activo, Qué rico come tu diputado, concentra 39.7%; los cinco primeros, 75.4%.
- Audiencia compartida escasa: 9 autores participan en varios videos y 7 son articulaciones verificadas. La bipartita tiene 351 nodos, 343 aristas y 10 componentes; las proyecciones no demuestran conversaciones.
- Visibilidad distinta de participación recolectada: Pearson $r=0.067$ en 19 videos no muestra asociación lineal fuerte; no prueba independencia ni permite atribuir diferencias a preferencias generales de espectadores.
- Contenido y estructura: Louvain encuentra 17 comunidades ($Q=0.7774$). Las tres mayores concentran 240 comentarios internos y contenido de Quorum sobre diputados, USAC, internet y movilidad urbana. Las frecuencias temáticas y los perfiles automáticos se interpretan conjuntamente, sin confundir críticas al personaje con rechazo al canal.
- Tono predicho, no opinión poblacional: NEG=249, NEU=78, POS=79. Se registran 11 textos truncados y 69 de baja confianza. Estas etiquetas y diferencias entre grupos requieren evaluación humana independiente antes de usos sustantivos.
- Conclusión de alcance: los resultados describen esta extracción de YouTube; no representan a todos los usuarios de la plataforma ni a la población de Guatemala.

Entregables y comprobaciones reproducibles

Las tablas CSV completas se escriben en `results/` : nodos con tipos, atributos, centralidades y comunidades; aristas bipartitas con peso y tipos de extremos; aristas de ambas proyecciones; evidencia de articulaciones; cobertura de los 293 videos; comentarios originales/limpios con sentimiento; resúmenes y métricas. El manifiesto conserva revisión del modelo y SHA-256 de insumos. La ejecución valida cada peso de proyección contra intersecciones reales de vecinos, incluyendo pares no conectados.

El comando `uv run lab6-ds` ejecuta este notebook desde un kernel limpio y produce `results/Informe_Laboratorio6.pdf` a partir de sus resultados y narrativa, sin incluir bloques de código. El notebook conserva las tablas completas; el PDF resume salidas extensas para legibilidad.

- Repositorio: <https://github.com/Qu3zada22/lab6-ds>
- Espacio colaborativo del grupo: Informe del Laboratorio 6 .

Validaciones aprobadas: `{'comments': 406, 'classified': 406, 'nodes': 351, 'edges': 343, 'projection_pairs_verified': 55117}`

: 0 | network: bipartite | nodes: 351 | edges: 343 | density: 0.054375 | mean_degree: 1.954416 | components: 10 | largest_component: 286 | isolates: 0 | transitivity: 0.000000 | average_clustering: 0.000000 | largest_component_mean_distance: 4.715250 | largest_component_diameter: 12

: 1 | network: authors | nodes: 332 | edges: 10732 | density: 0.195319 | mean_degree: 64.650602 | components: 10 | largest_component: 276 | isolates: 4 | transitivity: 0.984025 | average_clustering: 0.972049 | largest_component_mean_distance: 2.356495 | largest_component_diameter: 6

: 2 | network: videos | nodes: 19 | edges: 11 | density: 0.064327 | mean_degree: 1.157895 | components: 10 | largest_component: 10 | isolates: 9 | transitivity: 0.315789 | average_clustering: 0.149123 | largest_component_mean_distance: 2.488889 | largest_component_diameter: 5

Tabla extensa: se presentan hasta cinco registros. Consulte la tabla completa en el notebook/CSV.

